Modélisation statistique avancée

BUT SD 3A S5
2023-2024

Partie 1 : Rappels

Christophe REYPE

© 2023 Christophe REYPE
Document sous licence Creative Commons Attribution – Partage dans les mêmes conditions 4.0 International (CC BY-SA 4.0)
https://creativecommons.org/licenses/by-sa/4.0/

A propos de moi

- mail : christophe.reype@univ-lorraine.fr
- page personnelle : `https://sites.google.com/view/christophe-reype/accueil`

Structure du cours

- Rappels : 12H
- Statistique paramétrique : 16H
- Statistique non paramétrique : 16H
- Examen écrit

Références

- Radu Stoica
- Dress, F. (2007). Les probabilités et la statistique de A à Z : 500 définitions, formules et tests d'hypothèse. Dunod.
- FREDON, Daniel, MAUMY, Myriam, et BERTRAND, Frédéric. Mathématiques L1/L2 : Statistique et Probabilités en 30 fiches. Dunod, 2009.
- Goldfarb, B., & Pardoux, C. (2011). Introduction à la méthode statistique : manuel et exercices corrigés. Dunod.
- Krickeberg, K. (1996). Petit cours de statistique. Springer Science & Business Media.

Table des matières

Intérêt de la statistique

Définitions

Variable aléatoire

Les indicateurs

Statistique paramétrique/non paramétrique

Intérêt

La statistique est l'art de faire "parler" les données afin de mieux comprendre un phénomène aléatoire. La statistique permet de développer des outils d'aide à la prise de décision, des indicateurs de contrôle, ainsi que des outils pour modéliser des phénomènes aléatoires.

Exemples : sondages, surveillance des épidémies, répartition des arbres dans une forêt...

Exemple 1 : Etude internationale sur l'image du transport aérien (sondage)

- sondage de l'IFOP (Institut français d'opinion publique)
- date du rapport 16 juin 2023
- `https://www.ifop.com/publication/etude-internationale-sur-limage-du-transport-aerien/`

Quelles sont les données ?

- échantillon représentatif de la population nationale âgée de plus de 18 ans dans différents pays
- échantillon représentatif par la méthode des quotas après stratification par régions
- données obtenues par questionnaire auto-administré en ligne du 7 au 9 juin 2023
- les réponses sont qualitatives : à chaque question l'individu répond "réponse numéro i"

Intérêts de l'étude

- faisabilité d'un nouvel aéroport
- investissement dans le développement d'un moyen de transport (avion ou alternatif)
- marketing : associer l'image d'une marque à l'avion ?
- ...

Exemple 2 : Territoires ruraux : perceptions et réalités de vie face aux défis des transitions (sondage)

- sondage de l'IFOP (Institut français d'opinion publique)
- date du rapport 14 juin 2023
- `https://www.ifop.com/publication/territoires-ruraux-perceptions-et-realites-de-vie-face-aux-defis-des-transitions/`

Quelles sont les données ?

- échantillon représentatif de la population nationale âgée de plus de 18 ans
- échantillon représentatif par la méthode des quotas après stratification par régions
- données obtenues par questionnaire auto-administré en ligne du 4 au 5 mai 2023

Intérêts de l'étude

- comprendre les problématiques et les challenges des territoires ruraux

Limites de l'étude

- les régions n'ont pas forcément les mêmes problématiques (climat/environnement, emploi, population, infrastructure,...)
- les individus ont **choisi** de répondre à un questionnaire en ligne : seuls ceux capable d'utiliser internet ont pu répondre

Question Donnez des exemples de données quantitatives

- nombre d'enfants par foyer
- salaire
- distance domicile/travail
- ...

Exemple 3 : InfoCovidFrance (rapport hebdomadaire)

- rapport hebdomadaire de Santé publique France
- date du rapport 28 juin 2023
- `https://www.santepubliquefrance.fr/dossiers/coronavirus-covid-19/coronavirus-chiffres-cles-et-evolution-de-la-covid-19-en-france-et-dans-le-monde`

Quelles sont les données ?

- médecine libérale et hospitalière, urgences, laboratoires de biologie médicale hospitaliers et de ville, sociétés savantes d'infectiologie, de réanimation, de médecine d' urgence, Cnam, Inserm, Insee.

Exemple 4 : Résultats 2022 de l'Inventaire forestier national : une forêt française confrontée aux dérèglements climatiques (communiqué de presse)

- communiqué de presse de l'IGN (Institut national de l'information géographique et forestière (IGN)
- communiqué de presse 21 octobre 2022
- `https://ign.fr/espace-presse/resultats-2022-de-linventaire-forestier-national-une-foret-francaise-confrontee-aux-dereglements`

Intérêts de l'étude

- surveillance
- alerte
- prévention

D'autres jeux de données disponible

- https://www.data.gouv.fr/fr/pages/thematiques-a-la-une/
- https://www.insee.fr/fr/accueil

La statistique

La statistique se compose de trois parties :

- **statistique descriptive** recueillir/décrire/résumer les données *(état des lieux)*
- **statistique inférentielle I : modélisation** définir un modèle statistique *(comprendre et prédire un phénomène)*
- **statistique inférentielle II : tests d'hypothèses** contrôler et valider le modèle

Exemple Nombre d'individus qui entrent dans l'IUT

- **statistique descriptive** nombre moyen hebdomadaire, heures d'affluence, y a-t-il des jours où il y a plus de 3ème année ou de personnes d'un département ?
- **statistique inférentielle I : modélisation** définir le modèle de fréquentation et prédire sur l'année la fréquentation de l'IUT
- **statistique inférentielle II : tests d'hypothèses** le modèle proposé est-il le bon ?

Table des matières

Intérêt de la statistique

Définitions

Variable aléatoire

Les indicateurs

Statistique paramétrique/non paramétrique

Définitions

Population : Ensemble des éléments (individus) sur lequel repose l'étude statistique. La population est notée Ω.
Exemples : tous les étudiants de l'IUT, toutes les forêts en France, toutes les abeilles vivant dans une ruche ...

Individu : Elément constituant une population.
Exemples : une forêt en France, un pays parmi l'ensemble des pays

Caractère : Grandeur définie sur une population d'individus. Ce caractère peut être qualitatif (couleur des vêtements, être un chêne, ...) ou quantitatif (nombre de branches sur un arbre, distance parcouru en un jour, ...).

$$\begin{aligned} \chi : \Omega &\to C \\ \omega &\mapsto \chi(\omega) \end{aligned} \tag{1}$$

Echantillon : Résultats du tirage aléatoire de n individus dans une population.

Table des matières

Intérêt de la statistique

Définitions

Variable aléatoire
- Variable aléatoire discrète
- Variable aléatoire à densité

Les indicateurs

Statistique paramétrique/non paramétrique

Variable aléatoire

Definition (Variable aléatoire)

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé. Une **variable aléatoire** (v.a.) X est une application

$$\begin{aligned} X : \Omega &\to E \\ \omega &\mapsto X(\omega) \end{aligned} \tag{2}$$

Remarques :

- une variable aléatoire est une fonction qui associe à chaque individu un ensemble de caractéristiques (exemple : âge, adresse, couleur de vêtement d'un étudiant de l'IUT)
- les variables aléatoires sont notées en majuscule et les quantités déterministes en minuscule
- $X(\Omega)$ est l'ensemble des valeurs prises par X
- une variable qualitative peut être transformée en variable quantitative même si elle n'a pas de sens quantitatif (couleur de vêtement et moyenne)

Variable aléatoire réelle

Cas d'une variable aléatoire réelle (v.a.r.)

- $X^{-1}(\{x\}) = \{\omega \in \Omega | X(\omega) = x\}$ se note $\{X = x\}$
- $X^{-1}(]-\infty, a]) = \{\omega \in \Omega | X(\omega) \leq a\}$ se note $\{X \leq a\}$
- $X^{-1}([a, b]) = \{\omega \in \Omega | a \leq X(\omega) \leq b\}$ se note $\{a \leq X \leq b\}$

Variable aléatoire discrète

Definition (Loi d'une variable aléatoire discrète)

La loi de la variable aléatoire discrète X, notée $\mathcal{L}oi(X)$, est donnée par la suite $(\mathbb{P}(X = k) = p_X(k))_{k \in X(\Omega)}$ telle que

- $\forall k \in X(\Omega) : \; p_X(k) \geq 0$
- $\sum_{k \in X(\Omega)} p_X(k) = 1$
- $\forall x \in \mathbb{R} : \; \mathbb{P}(X \leq x) = \sum_{k \leq x} p_X(k)$

k	1	2	3	4	5
x_k	paresseux	hippopotame	papillon	cafard	capybara
x_k	1	2	3	4	5
$p_X(k)$	0.05	0.1	0.28	0.2	0.37
$\mathbb{P}(X \leq x)$	0.05	0.15	0.43	0.63	1

Table – Exemple de loi : animal totem.

Calculs avec la loi de X

- $\sum_{x \in X(\Omega)} \mathbb{P}(X = x) = 1$
- espérance : $\mathbb{E}(X) = \sum_{x \in X(\Omega)} x\mathbb{P}(X = x)$
- $\mathbb{E}(X^2) = \sum_{x \in X(\Omega)} x^2\mathbb{P}(X = x)$
- théorème de transfert : $\mathbb{E}(g(X)) = \sum_{x \in X(\Omega)} g(x)\mathbb{P}(X = x)$
- variance : $var(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- écart-type : $\sigma_X = \sqrt{var(X)}$

Rappel sur les couples de variables

Loi du couple/ loi jointe

- $\mathbb{P}([X = x] \cap [Y = y]) = p_{X,Y}(x, y)$

Lois marginales

- $\mathbb{P}(X = x) = \sum_{y \in Y(\Omega)} p_{X,Y}(x, y)$,
  $\mathbb{P}(Y = Y) = \sum_{x \in X(\Omega)} p_{X,Y}(x, y)$

Loi conditionnelle

- $\mathbb{P}(Y = y | X = x) = \frac{\mathbb{P}([X=x] \cap [Y=y])}{\mathbb{P}(X=x)}$
- $\mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}([X=x] \cap [Y=y])}{\mathbb{P}(Y=y)}$

Indépendance

- $\mathbb{P}([X = x] \cap [Y = y]) = \mathbb{P}(X = x)\mathbb{P}(Y = y)$
- X et Y sont indépendants $\Rightarrow \mathbb{P}(Y = y | X = x) = \mathbb{P}(Y = y)$
  et $\mathbb{P}(X = X | Y = y) = \mathbb{P}(X = x)$

Loi uniforme discrète

X suit une loi uniforme discrète si elle prend chaque valeur $a, a+1, ..., b-1, b$ avec probabilité $\frac{1}{b-a}$

- $\forall k \in [[a, b]] : \mathbb{P}(X = k) = \frac{1}{(b-a)}$
- espérance $\mathbb{E}(X) = \frac{a+b}{2}$
- variance $var(X) = \frac{(b-a)(b-a+2)}{12}$
- s'utilise si l'expérience à $b - a$ issues équiprobable

Loi de Bernoulli

X suit une loi de Bernoulli de paramètre p, notée $\mathcal{B}(p)$, si elle résulte en un succès avec probabilité p et en un échec avec probabilité $1-p$.

- $\mathbb{P}(X=1)=p$ et $\mathbb{P}(X=0)=1-p$
- espérance $\mathbb{E}(X)=p$
- variance $var(X)=p(1-p)$
- s'utilise si l'expérience à deux issues possible : un succès avec probabilité p et un échec avec probabilité $1-p$
- exemple : lancer d'une pièce

Loi binomiale

X suit une loi binomiale de paramètre n et p, notée $\mathcal{B}inom(n, p)$, si elle compte le nombre de succès obtenues en répétant n expérience indépendante de Bernoulli de paramètre p

- $\forall k \in [[0, n]] : \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$
- espérance $\mathbb{E}(X) = np$
- variance $var(X) = np(1-p)$
- s'utilise si nous comptons le nombre de réussite obtenu en répétant une expérience de Bernoulli de paramètre p de manière indépendante n fois
- exemple : nombre de fois où pile est apparu

Loi hypergéométrique

X suit une loi Hypergéométrique de paramètre N, n et p, notée $\mathcal{H}(N, p, n)$, si elle compte parmi un échantillon de taille n le nombre d'individus dans une catégorie sachant que la population totale est de taille N et que la proportion de la population appartenant à la catégorie est p.

- $\forall k \in [[0, n]] : \mathbb{P}(X = k) = \frac{\binom{Np}{k}\binom{N-Np}{n-k}}{\binom{N}{n}}$
- espérance $\mathbb{E}(X) = np$
- variance $var(X) = np(1-p)\frac{N-n}{N-1}$
- exemple : nombre de personne qui porte des lunettes sachant que 40% de la population porte des lunettes

Loi hypergéométrique à m catégories

X suit une loi Hypergéométrique à m catégories de paramètre N, n et $p_1, ..., p_m$, si

$\forall k \in [[0, n]] : \mathbb{P}(k_1, \cdots, k_m) = \frac{\binom{Np_1}{k_1}\binom{Np_2}{k_2}...\binom{Np_m}{k_m}}{\binom{N}{n}}$

- $\sum_{i=1}^{m} k_i = n$
- $\sum_{i=1}^{m} p_i = 1$

Loi géométrique

X suit une loi géométrique de paramètre p, notée $\mathcal{G}eom(p)$, si elle compte le nombre d'essais nécessaire avant d'obtenir un premier succès en répétant des expériences de Bernoulli de paramètre p de manière indépendante

- $\forall k \in \mathbb{N} : \mathbb{P}(X = k) = (1-p)^{k-1}p$
- espérance $\mathbb{E}(X) = 1/p$
- variance $var(X) = \frac{1-p}{p^2}$
- exemple : nombre de succès avant d'atteindre une cible

Loi de Poisson

X suit une loi de Poisson de paramètre λ, notée $\mathcal{P}oisson(\lambda)$, si elle compte le nombre de succès obtenu en une unité de temps sachant que le nombre moyen de succès par unité de temps est de λ

- $\forall k \in \mathbb{N} : \mathbb{P}(X = k) = \exp(-\lambda)\frac{\lambda^k}{k!}$
- espérance $\mathbb{E}(X) = \lambda$
- variance $var(X) = \lambda$
- exemple : nombre de personne qui rentre dans la salle en 1 heure

Indépendance : Le nombre de succès sur des unités de temps disjointes sont indépendants

Variable aléatoire à densité

Definition (Densité de probabilité)

Une fonction $f : \Omega \to \mathbb{R}$ est une densité de probabilité de la variable aléatoire X à valeurs dans $\mathbb{R}$ si

$$\forall A \in \mathcal{F} : \mathbb{P}(X \in A) = \int_A f(x)dx. \tag{3}$$

$$f \text{ est une densité} \Leftrightarrow \begin{cases} f \text{ est intégrable sur } \Omega \\ \displaystyle\int_\Omega f(x)dx = 1 \\ f \text{est presque partout positive ou nulle sur } \Omega \end{cases}$$

Calculs avec la loi de X

- $\mathbb{P}(a \leq X \leq b) = \int_a^b f(y)dy$
- $\mathbb{P}(X \leq b) = \int_{-\infty}^b f(y)dy$
- $\int_{X(\Omega)} f(y)dy = \int_{-\infty}^{\infty} f(y)dy = 1$
- espérance : $\mathbb{E}(X) = \int_{X(\Omega)} yf(y)dy$
- $\mathbb{E}(X^2) = \int_{X(\Omega)} y^2 f(y)dy$
- $\mathbb{E}(g(X)) = \int_{X(\Omega)} g(y)f(y)dy$
- variance : $var(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- écart-type : $\sigma_X = \sqrt{var(X)}$

Rappel sur les couples de variables

Loi du couple/ loi jointe

- $f_{X,Y}(x,y)$

Lois marginales

- $f_X(x) = \int_{Y(\Omega)} f_{X,Y}(x,y)dy$,
  $f_Y(y) = \int_{X(\Omega)} f_{X,Y}(x,y)dx$,

Loi conditionnelle

- $f_{Y|X}(y,x) = \frac{f_{X,Y}(x,y)}{f_X(x)}$
- $f_{X|Y}(x,y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$

Indépendance

- $f_{X,Y}(x,y) = f_X(x)f_Y(y)$

Loi uniforme

X suit une loi uniforme sur $[a, b]$, notée $\mathcal{U}([a, b])$, si la probabilité sur tout intervalle est la même que la probabilité sur tout autre intervalle de même longueur

- $\forall x \in \mathbb{R} : \ f(x) = \frac{1}{b-a} \mathbb{1}_{x \in [a,b]}$
- espérance $\mathbb{E}(X) = \frac{a+b}{2}$
- variance $var(X) = \frac{(b-a)^2}{12}$

Loi exponentielle

X suit une loi exponentielle de paramètre λ, notée $\mathcal{E}xp(\lambda)$, si elle modélise le temps ou la distance entre deux évènements sachant que les évènements se produisent de manière indépendante avec un même taux. La quantité moyenne est de λ

- $\forall x \in \mathbb{R} : \ f(x) = \lambda \exp\{-\lambda x\} \mathbb{1}_{x \in \mathbb{R}_+}$
- espérance $\mathbb{E}(X) = \frac{1}{\lambda}$
- variance $var(X) = \frac{1}{\lambda^2}$
- $\forall x_1, x_2 \in \mathbb{R}_+ \ : \mathbb{P}(x_1 \leq X \leq x_2) = \exp\{-\lambda x_1\} - \exp\{-\lambda x_2\}$
- $\forall x \in \mathbb{R}_+ : \ \mathbb{P}(X \leq x) = \mathbb{P}(0 \leq X \leq x) = 1 - \exp\{-\lambda x\}$

Loi normale

X suit une loi normale ou gaussienne de paramètre 0 et 1 (loi gaussienne centrée-réduite), notée $\mathcal{N}(0,1)$, si sa moyenne est de 0 et sa variance de 1 et telle que

- $\forall x \in \mathbb{R} : \ f(x) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{x^2}{2})$
- espérance $\mathbb{E}(X) = 0$
- variance $var(X) = 1$

X suit une loi normale ou gaussienne de paramètre μ et σ^2, notée $\mathcal{N}(\mu, \sigma^2)$, si sa moyenne est de μ et sa variance de σ^2 et telle que

- $\forall x \in \mathbb{R} : \ f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2})$
- espérance $\mathbb{E}(X) = \mu$
- variance $var(X) = \sigma^2$

Rappel sur les propriétés

Propriétés de la probabilité :

- $\forall x \in \mathbb{R} : \mathbb{P}(X \leq x) = 1 - \mathbb{P}(X > x)$
- $\forall x \in \mathbb{R} : \mathbb{P}(X \geq x) = 1 - \mathbb{P}(X < x)$
- $\forall (x, y) \in \mathbb{R} : \mathbb{P}(x \leq X \leq y) = \mathbb{P}(X \leq y) - \mathbb{P}(X < x)$
- si X est une variable aléatoire à densité
  $\forall x \in \mathbb{R} : \mathbb{P}(X \leq x) = \mathbb{P}(X < x)$

Propriétés de l'espérance :

- $\forall a, b \in \mathbb{R} : \mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- si X et Y sont indépendantes $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$

Propriétés de la variance :

- $var(X) = \mathbb{E}\left((X - \mathbb{E}(X))^2\right) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$
- $\forall a, b \in \mathbb{R} : var(aX + b) = a^2 var(X)$
- $var(X + Y) = var(X) + var(Y) + 2cov(X, Y)$
- $cov(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$

Fonction de répartition

Definition (Fonction de répartition)

La fonction de répartition F de la variable aléatoire réelle X est défini par

$$\forall x \in \mathbb{R} : \; F(x) = \mathbb{P}(X \leq x). \tag{4}$$

- Si X est discrète $\forall x \in \mathbb{R} : \; F(x) = \sum_{k \leq x} p_X(k)$
- Si X est continue $\forall x \in \mathbb{R} : \; F(x) = \int_{-\infty}^{x} f(y)dy$

Une fonction de répartition F a les propriétés suivantes :

- F est croissante
- F est continue à droite
- $\lim_{x \to +\infty} F(x) = 1$
- $\lim_{x \to -\infty} F(x) = 0$

Histogramme

- $X(\Omega)$ est découpé en un nombre fini I de classes $[x_{i-1}, x_i[$ de sorte que $X(\Omega) = \cup_{i=1}^{I} [x_{i-1}, x_i[$
- la fréquence de chaque classe $f_i = \frac{n_i}{n}$ est calculée (n est le nombre d'individus et n_i le nombre d'individus dans la classe i)

Histogramme Représentation graphique qui à chaque classe associe un rectangle d'aire ou de longueur proportionnelle à sa fréquence.

Les classes sont à adapter à chaque étude :

- si les classes ont la même amplitude, la longueur du rectangle est proportionnelle à la fréquence
- si les classes ont différentes amplitudes, l'aire du rectangle est proportionnelle à la fréquence
- un nombre de classe trop faible peut faire disparaître des particularités de la distribution

Histogramme : nombre de classes

Expérience : nombre de succès dans 100 duels pierre-papier-ciseaux.

Données : Un échantillon de 100 individus :10 individus ayant obtenus 9 succès et un individu pour chaque nombre de succès compris entre 11 et 100

Commande R : donnee=c(rep(9,10),11 :100)

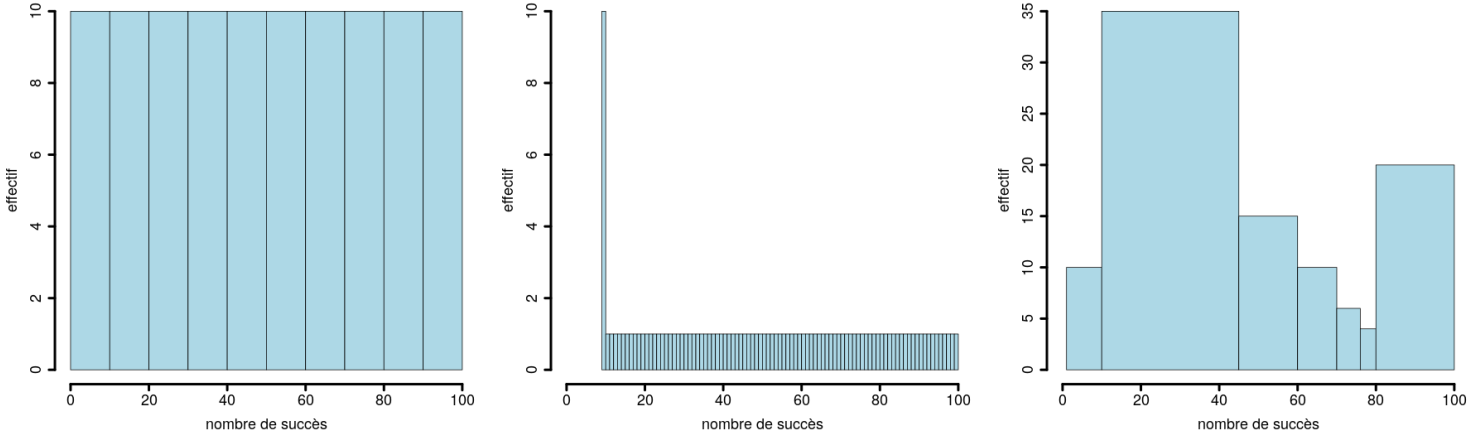

(a) 10 classes (b) 100 classes (c) classes adaptées

Figure – Histogramme des succès. Pour la figure (c), les classes sont $[1, 10[$, $[10, 46[$, $[46, 61[$, $[61, 71[$, $[71, 77[$, $[77, 81[$, $[81, 100]$

Représentation des variables aléatoires (1/3)

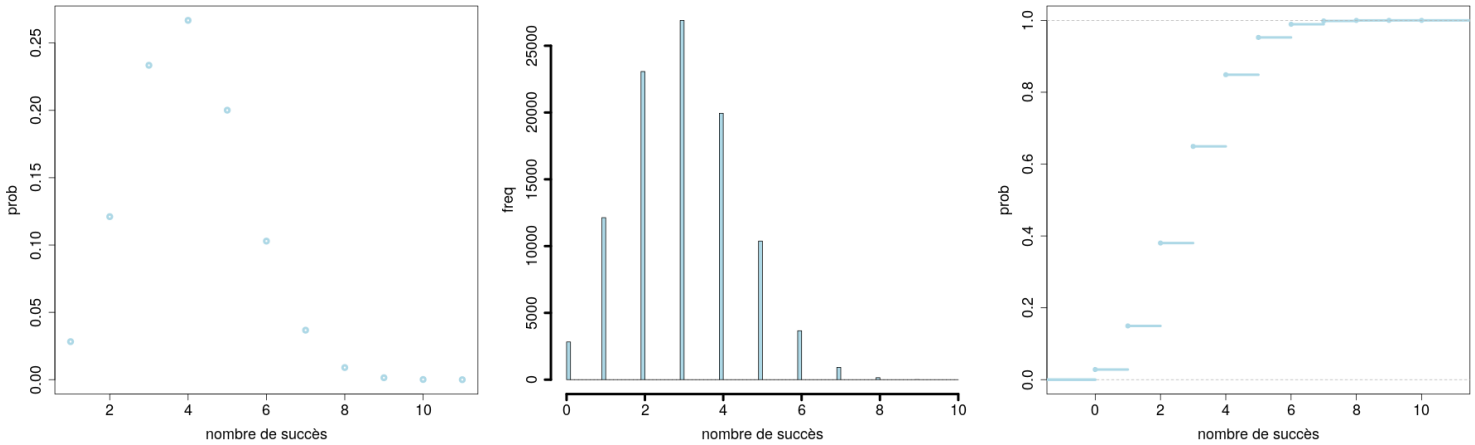

(a) Distribution (b) Histogramme (c) Fonction de répartition

Figure – Loi binomiale $\mathcal{B}inom(10, 0.3)$

Représentation des variables aléatoires (2/3)

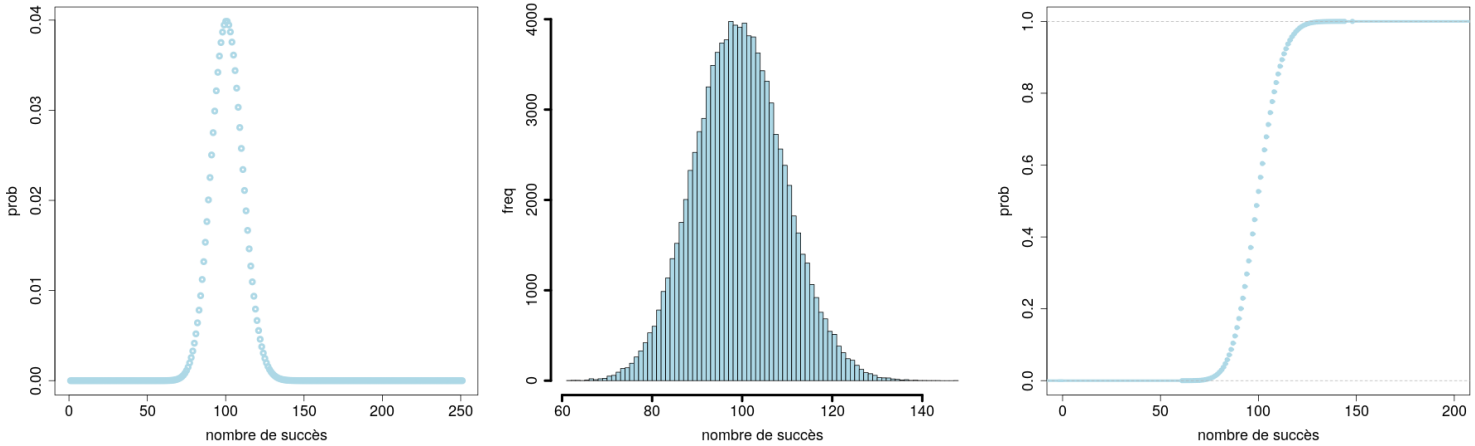

(a) Distribution (b) Histogramme (c) Fonction de répartition

Figure – Loi de Poisson $\mathcal{P}oisson(100)$

Représentation des variables aléatoires (3/3)

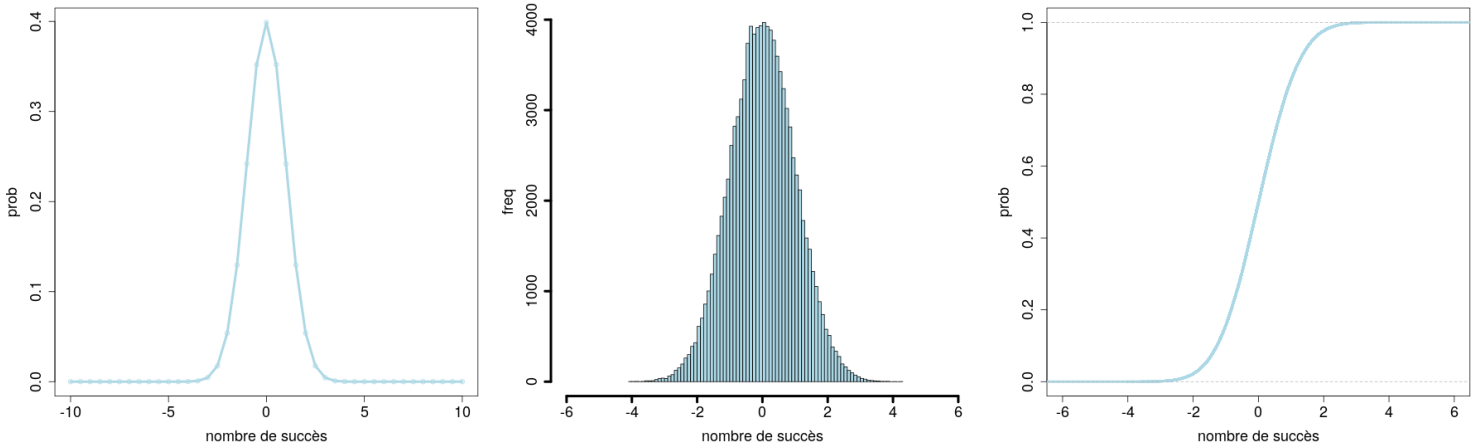

(a) Distribution (b) Histogramme (c) Fonction de répartition

Figure – Loi normale $\mathcal{N}(0, 1)$

Table des matières

Intérêt de la statistique

Définitions

Variable aléatoire

Les indicateurs
- Indicateurs de position
- Indicateurs de dispersion
- Indicateurs de forme

Statistique paramétrique/non paramétrique

Pourquoi utiliser des indicateurs statistiques ?

Problématique Comment visualiser la distribution d'une variable aléatoire ?

Nous pouvons caractériser la distribution par :

- la position de valeurs spécifiques de la distribution (moyenne, mode...)
- la variation de la distribution (étendue, écart type...)
- la forme de la distribution (symétrie de la distribution...)

Conditions de Yule

- Dans la suite nous considérons l'échantillon de variable aléatoire $X = (X_1, \cdots, X_n)$.
- La réalisation de X est composé de n observations $\mathbf{x} = (x_1, \cdots, x_n)$

Une statistique est une variable aléatoire fonction de l'échantillon (exemple : moyenne, mode, étendue, écart type...)

Une statistique doit :

1. être définie indépendamment de l'observateur
2. dépendre de toutes les observations
3. avoir un sens concret
4. être facilement calculable
5. être peu sensible à l'échantillonnage
6. se prêter aisément aux calculs algébriques

En pratique, il est rare d'avoir des statistiques qui possèdent tous ces critères.

Indicateurs de position

- La moyenne arithmétique : $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$
- Le mode : classe de l'histogramme la plus représentée
- La médiane : m_e tel que $\mathbb{P}(X \leq m_e) = 0.5$
- Le α-quantile : q_α tel que $\mathbb{P}(X \leq q_\alpha) = \alpha$

D'autres moyennes

- La moyenne géométrique
  - $G = \left(\prod_{i=1}^{n} x_i\right)^{1/n} \Rightarrow \ln(G) = \frac{1}{n}\sum_{i=1}^{n} \ln(x_i)$
  - conserve le produit des x_i
- La moyenne harmonique
  - $H = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$
  - conserve la somme des inverses des x_i
  - utilisé si l'inverse a un sens comme pour les taux

Indicateurs de dispersion

- L'étendue : $\max_{1 \leq i \leq n} x_i - \min_{1 \leq i \leq n} x_i$
- L'étendue interquartile : $q_{0.75} - q_{0.25}$
- L'écart absolu moyen : $\frac{1}{n} \sum_{i=1}^{n} |x_i - \overline{x}|$
- L'écart type (s_X)/ la variance $(var(X))$:
  $var(X) = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})^2 \Rightarrow s_X = \sqrt{var(X)}$
- Le moment d'ordre r : $m_r = \frac{1}{n} \sum_{i=1}^{n} x_i^r$
- Le moment centré d'ordre r : $\mu_r = \frac{1}{n} \sum_{i=1}^{n} (x_i - m)^r$

Indicateurs de forme

Un indicateur d'asymétrie (skewness)

- coefficient d'asymétrie de Fisher
  - $\gamma_1 = \frac{\mu_3}{s_X^3}$
  - si $\gamma_1 = 0$ la distribution est symétrique, si $\gamma_1 > 0$ la distribution s'étale à droite, si $\gamma_1 < 0$ la distribution s'étale à gauche

Un indicateur d'aplatissement (kurtosis)

- coefficient d'aplatissement de Fisher
  - $\gamma_2 = \frac{\mu_4}{s_X^4} - 3$
  - si $\gamma_2 = 0$ la distribution est gaussienne, si $\gamma_2 > 0$ la distribution est moins aplatie que la gaussienne, si $\gamma_2 < 0$ la distribution est plus aplatie que la gaussienne

Boxplot

La boîte à moustaches/ boîte de dispersion/ boîte de distribution/ boxplot résume certain indicateurs.

Un boxplot est composé :

- d'une boite
  - le bord inférieur de la boite est le premier quartile $q_{0.25}$
  - le segment est la médiane m_e
  - le bord supérieur de la boite est le troisième quartile $q_{0.75}$
- de deux moustaches
  - la limite inférieure des valeurs éloigné est à $q_{0.25} - 1.5(q_{0.75} - q_{0.25})$
  - la limite supérieure des valeurs éloigné est à $q_{0.75} + 1.5(q_{0.75} - q_{0.25})$

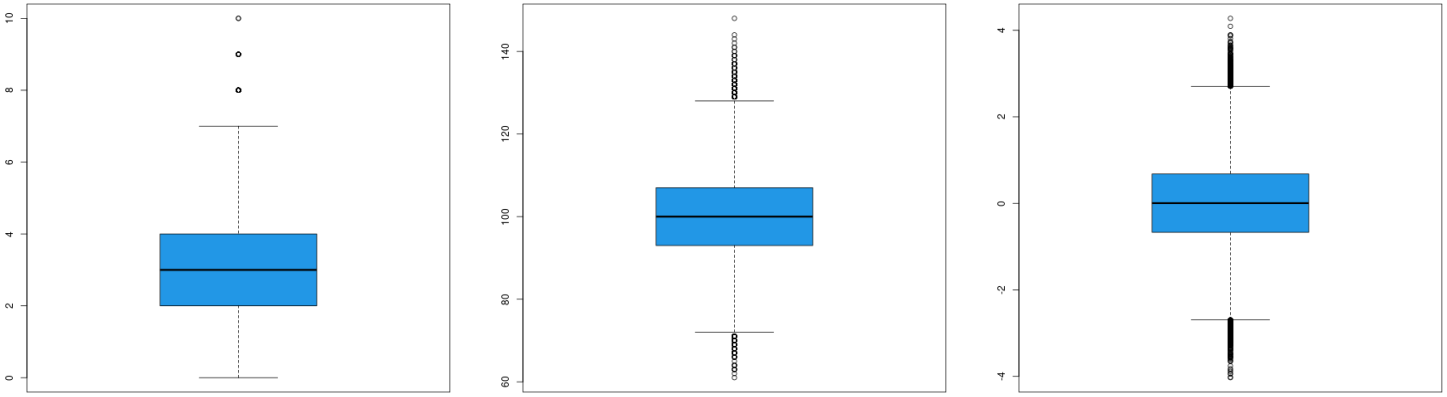

(a) $\mathcal{B}inom(10, 0.3)$ (b) $\mathcal{P}oisson(100)$ (c) $\mathcal{N}(0, 1)$

Figure – Boxplot pour différentes lois usuelles.

Table des matières

Intérêt de la statistique

Définitions

Variable aléatoire

Les indicateurs

Statistique paramétrique/non paramétrique

Différence entre statistique paramétrique et statistique non paramétrique

Nous nous intéressons à la variable aléatoire X qui suit la loi $\mathcal{L}oi(X)$.

- dans le cas de la statistique paramétrique, cette loi est entièrement définie à partir d'un certain nombre de paramètre (voir les lois usuelles)
- dans le cas de la statistique non paramétrique, $\mathcal{L}oi(X)$ n'est pas connu

Modélisation statistique avancée

BUT SD 3A S5
2023-2024

Partie 2 : Statistique paramétrique

Christophe REYPE

© 2023 Christophe REYPE
Document sous licence Creative Commons Attribution – Partage dans les mêmes conditions 4.0 International (CC BY-SA 4.0)
https://creativecommons.org/licenses/by-sa/4.0/

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Problématique Nous souhaitons étudier une population et déduire des propriétés de cette population.
Contexte Nous disposons d'un échantillon d'observations de taille n. Cet échantillon rassemble la mesure d'une caractéristique de n individus tirés aléatoirement.
Hypothèse 1 L'échantillon est représentatif de la population. Les observations x_i sont des réalisations d'une variable aléatoire X.
Hypothèse facultative Les observations sont indépendantes.
Résumé Nous étudions des statistiques T qui sont des fonctions des variables aléatoires $(X_1, \cdots, X_n)$.
Important Dans ce chapitre nous supposons que les X_i sont indépendant et identiquement distribués selon une loi $\mathcal{L}oi(X)$ définit par en ensemble de paramètres.

Question Dans les exemples suivants, quelles sont les observations et les statistiques ?

- étude de la durée de vie d'un appareil
- étude du nombre d'utilisateurs
- étude sur les trajets domicile-travail

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Théorèmes fondamentaux des statistiques

Loi faible des grands nombres Soient $X_1, \ldots, X_n$ indépendantes d'espérance m_i et de variance σ_i^2 finies.

$$\left.\begin{array}{l} \frac{1}{n}\sum_{i=1}^{n} X_i \to \mathbb{E}(X) \\ \frac{1}{n^2}\sum_{i=1}^{n} \sigma_i^2 \to 0 \end{array}\right\} \Rightarrow \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathcal{P}} \mathbb{E}(X) \tag{1}$$

Théorème central limite Soient $X_1, \ldots, X_n$ indépendantes et identiquement distribuées d'espérance μ et de variance σ^2 finies. Alors

$$\frac{\frac{1}{n}\sum_{i=1}^{n} X_i - \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}(X_i)}{\sqrt{\sigma^2/n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1). \tag{2}$$

et

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathcal{L}} \mathcal{N}(\frac{1}{n}\sum_{i=1}^{n} \mathbb{E}(X_i), \sigma^2/n). \tag{3}$$

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Pourquoi les moments

Hypothèse Nous étudions une variable aléatoire X dont la loi est déterminée par des paramètres

Definition

Le moment théorique d'ordre r d'une variable aléatoire X est donnée par $\mathbb{E}(X^r)$.

Definition

Le moment d'ordre r d'un échantillon (ou moment empirique d'ordre r) est donnée par $m_r = \frac{1}{n}\sum_{i=1}^{n} x_i^r$

Proposition Une loi est définie par ses moments

Cas général L'estimateur du moment d'ordre r est $\frac{1}{n}\sum_{i=1}^{n} x_i^r$

Moyenne

- L'estimateur de la moyenne est $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$
- La moyenne de l'échantillon est $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$

Variance

- L'estimateur de la variance est $V = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2$
- La variance de l'échantillon est $v = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$
- L'estimateur non biaisé de la variance est $S^2 = \frac{n}{n-1}V$
- La variance non biaisé de l'échantillon est $s^2 = \frac{n}{n-1}v$

Proposition Pour toute variable X d'espérance μ et de variance σ^2

- $\mathbb{E}(\bar{X}) = \mu$
- $var(\bar{X}) = \frac{\sigma^2}{n}$
- $\mathbb{E}(V) = \frac{n-1}{n}\sigma^2$
- $\mathbb{E}(S^2) = \sigma^2$

Remarque $\bar{X}$ et S^2 sont dits estimateurs non biaisé car leur espérance est égale à la quantité qu'ils estiment.

Proposition Les paramètres peuvent être estimés à partir des moments de la variable aléatoire.

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Méthode Delta

La méthode Delta est une extension du théorème central limite

Méthode Delta Soient $X_1, \ldots, X_n$ indépendantes et identiquement distribuées d'espérance μ et de variance σ^2 finies. Alors, pour toute fonction g dérivable telle que $g'(\mu) \neq 0$

$$\sqrt{n}(g(\bar{X}) - g(\mu)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, [\sigma g'(\mu)]^2) \tag{4}$$

d'où

$$g(\bar{X}) \xrightarrow{\mathcal{L}} \mathcal{N}(g(\mu), \frac{[\sigma g'(\mu)]^2}{n}). \tag{5}$$

Proposition La méthode delta est utilisé pour obtenir une approximation de la distribution asymptotique d'une variable aléatoire

Méthode Delta : application à une loi binomiale

Contexte Nous nous intéressons à la proportion de personnes portant des lunettes. Dans un échantillon de taille n, le nombre de personnes portant des lunettes est données par la variable aléatoire $X \sim \mathcal{B}inomial(n, p)$.

Rappels

- $\mathbb{E}(X) = np$, $var(X) = np(1-p)$
- par le théorème central limite, pour n assez grand $X \sim \mathcal{N}(np, np(1-p))$

Calcul de la proportion La proportion dans l'échantillon est donnée par $F = X/n$

- $\forall x \in \mathbb{R} : \ g'(x) = 1/n$
- par la méthode Delta
  - $g(X) \xrightarrow{\mathcal{L}} \mathcal{N}(g(\mathbb{E}(X)), \frac{var(X)[g'(\mathbb{E}(X))]^2}{n})$
  - $g(X) \xrightarrow{\mathcal{L}} \mathcal{N}(p, \frac{p(1-p)}{n})$
  - $F \sim \mathcal{N}(p, \frac{p(1-p)}{n})$
  - $g_1(F) \sim \mathcal{N}(g_1(p), \frac{p(1-p)[g_1'(p)]^2}{n})$

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Variance d'un estimateur

Definition (Information de Fisher)

La quantité d'information de Fisher apportée par un échantillon de taille n sur le paramètre θ est

$$I_n(\theta) = -\mathbb{E}\left[\frac{d^2 L(x_1, \cdots, x_n; \theta)}{d\theta^2}\right] \tag{6}$$

Borne de Cramér-Rao

- Pour tout estimateur sans biais T d'un paramètre θ $var(T) \geq \frac{1}{I_n(\theta)}$
- Pour tout estimateur sans biais T de $h(\theta)$ $var(T) \geq \frac{[h'(\theta)]^2}{I_n(\theta)}$
- Si un estimateur atteint cette borne minimale de la variance alors il est dit **efficace**

Erreur quadratique moyenne

Definition (Erreur quadratique moyenne)

La qualité d'un estimateur T d'un paramètre θ est déterminée par son erreur quadratique moyenne (mean square error en anglais) définie par

$$MSE(T) = \mathbb{E}\left[(T-\theta)^2\right] = Biais(T)^2 + var(T) = (\mathbb{E}(T)-\theta)^2 + var(T) \tag{7}$$

- Dilemme biais-variance : en pratique moins un estimateur sera biaisé, plus sa variance sera forte. Inversement plus un estimateur aura une variance faible et plus son biais sera important
- En pratique, nous chercherons l'estimateur sans biais de variance minimale

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Vraisemblance

Definition (Vraisemblance)

La vraisemblance sachant les paramètres du modèle θ est la probabilité (densité de probabilité dans le cas continue) d'obtenir l'échantillon $\mathbf{x} = (x_1, \cdots, x_n)$ sachant θ notée $L(x_1, \cdots, x_n; \theta)$.

- **cas discret** $L(x_1, \cdots, x_n; \theta) = \mathbb{P}(X_1 = x_1 \cap \cdots \cap X_n = x_n | \theta)$
- **cas continu** $L(x_1, \cdots, x_n; \theta) = f_{X_1, \cdots, X_n | \theta}(x_1, \cdots, x_n | \theta)$

Remarques

- Si les variables aléatoires sont indépendantes
  - **cas discret** $L(x_1, \cdots, x_n; \theta) = \prod_{i=1}^{n} \mathbb{P}(X_i = x_i | \theta)$
  - **cas continu** $L(x_1, \cdots, x_n; \theta) = \prod_{i=1}^{n} f_{X_i | \theta}(x_i | \theta)$
- en pratique nous nous intéressons à la log-vraisemblance
  - **cas discret** $\ell(x_1, \cdots, x_n; \theta) = \sum_{i=1}^{n} \log(\mathbb{P}(X_i = x_i | \theta))$
  - **cas continu** $\ell(x_1, \cdots, x_n; \theta) = \sum_{i=1}^{n} \log(f_{X_i | \theta}(x_i | \theta))$

Maximum de vraisemblance

Idée L'échantillon obtenu est le plus probable. Il faut trouver θ qui maximise la vraisemblance
Le maximum de vraisemblance $\hat{\theta}$ est donnée par

$$\hat{\theta} = \arg\max_{\theta \in \Theta} L(x_1, \cdots, x_n; \theta) = \arg\max_{\theta \in \Theta} \ell(x_1, \cdots, x_n; \theta) \tag{8}$$

Si $\hat{\theta}$ existe alors il s'agit d'un θ tel que

$$\frac{dL(x_1, \cdots, x_n; \theta)}{d\theta} = \frac{d\ell(x_1, \cdots, x_n; \theta)}{d\theta} = 0 \tag{9}$$

Important Il faut vérifier que $\hat{\theta}$ est bien un maximum

Proposition Si $\hat{\theta}$ est l'estimateur du maximum de vraisemblance de θ alors $g(\hat{\theta})$ est l'estimateur du maximum de vraisemblance de $g(\theta)$.

Variance asymptotique du maximum de vraisemblance

- $\frac{\hat{\theta}-n}{\frac{1}{\sqrt{I_n(\theta)}}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$
- asymptotiquement $var(\hat{\theta}) \to \frac{1}{I_n(\theta)}$
- $\hat{\theta}$ est asymptotiquement efficace

Forme exponentielle

Definition

La loi de X est de forme exponentielle si

$$\log(f(x,\theta)) = a(x)\alpha(\theta) + b(x) + \beta(\theta)$$
$$\Leftrightarrow f(x,\theta) = \exp\left(a(x)\alpha(\theta) + b(x) + \beta(\theta)\right)$$

Si X est de forme exponentielle

- l'estimateur de $\frac{-\beta'(\theta)}{\alpha(\theta)}$ est $T = \frac{1}{n}\sum_{i=1}^{n} a(X_i)$
- la variance minimale de T est $V(T) = \frac{-1}{n\alpha'(\theta)}\frac{d}{d\theta}\left(\frac{\beta'(\theta)}{\alpha'(\theta)}\right)$

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Intérêt de la régression

Données

- Une variable X et un jeu de données $\mathbf{x} = (x_1, \ldots, x_n)$
- Une variable Y et un jeu de données $\mathbf{y} = (y_1, \ldots, y_n)$

Objectif Trouver une fonction f de X pour approximer Y

Conditions

- la fonction minimise $\mathbb{E}[(Y - f(X))^2]$
- la fonction est de la forme $\alpha + \beta X + \epsilon$
- ϵ suit une loi gaussienne centrée

Remarque la fonction qui minimise $\mathbb{E}[(Y - f(X))^2]$ est $\mathbb{E}(Y|X)$

Régression linéaire

En prenant l'espérance
$\mathbb{E}(Y) = \alpha + \beta\mathbb{E}(X)$
La droite de régression passe par $(\mathbb{E}(X), \mathbb{E}(Y))$.

Donc
$Y - \mathbb{E}(Y) = \beta(X - \mathbb{E}(X)) + \epsilon$.

En multipliant par $X - \mathbb{E}(X)$ et en prenant l'espérance
$\mathbb{E}\left[(Y - \mathbb{E}(Y))(X - \mathbb{E}(X))\right] = \beta\mathbb{E}\left[(X - \mathbb{E}(X))^2\right] + \mathbb{E}\left[\epsilon(X - \mathbb{E}(X))\right]$

Or $\mathbb{E}(\epsilon) = 0$ donc
$cov(X, Y) = \beta var(X) + cov(\epsilon, X)$.

De plus ϵ est non corrélé à X, d'où $\beta = \frac{cov(X,Y)}{var(X)}$.

Ainsi, $\alpha = \mathbb{E}(Y) - \frac{cov(X,Y)}{var(X)}\mathbb{E}(X)$

Conditions d'application de la régression linéaire

La régression linéaire peut s'appliquer si les conditions suivantes sont validées :

- les observations sont indépendantes
- le lien entre X et Y est linéaire
- les résidus doivent
  - être distribués selon une loi gaussienne
  - avoir la même variance (**homoscédasticité**)

Test de la significativité de β

Hypothèse

- $H_0 : \beta = 0$
- $H_1 : \beta \neq 0$ (unilatérale)
- $H_1 : \beta < 0$ ou $\beta > 0$ (bilatérale)

Statistique de test

- $T = \frac{\beta}{s_\beta} \sim Student(n-2)$ avec $s_\beta = \sqrt{\frac{\frac{s_y^2}{s_x^2} - \beta}{n-2}}$

Résultat

- bilatéral
  - $t \geq t_{5\%}$, H_0 rejetée, Y est liée à X
  - $t < t_{5\%}$, H_0 pas rejetée, pas de lien entre Y et X
- unilatéral
  - $t \geq t_{10\%}$, H_0 rejetée, Y est liée à Y positivement ou négativement à X
  - $t < t_{10\%}$, H_0 pas rejetée, pas de lien entre Y et X

Vérification des conditions : méthodes graphiques

Les résidus standardisés sont calculés à partir des résidus :

- $\hat{\epsilon}_i = \frac{\epsilon_i}{s_\epsilon}$

Les méthodes graphiques s'appliquent sur les résidus standardisés :

- le lag plot peut montrer l'absence d'auto-corrélation
- le boxplot peut montrer la symétrie de la distribution
- l'histogramme peut montrer une distribution en cloche centrée en 0
- Le Q-Q plot peut montrer un lien linéaire entre
  - les quantiles empiriques et les quantiles théoriques de la loi gaussienne (normalité)
  - les quantiles empiriques de deux variables

Lag plot

L'hypothèse d'indépendance est fixée par le protocole expérimental. Un cas de non indépendance est celui où la variable explicative X dépend du temps : les résidu peuvent alors être auto-corrélés

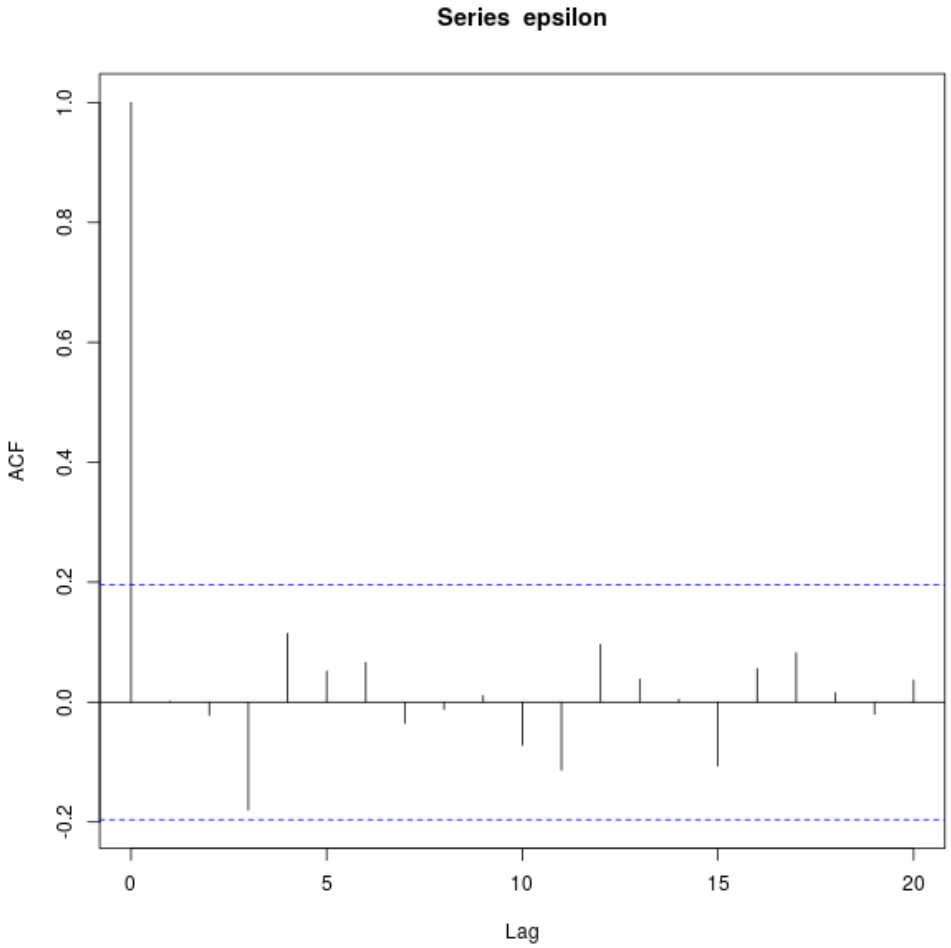

Boxplot

Les boxplots doivent montrer une distribution symétrique pour vérifier la normalité.

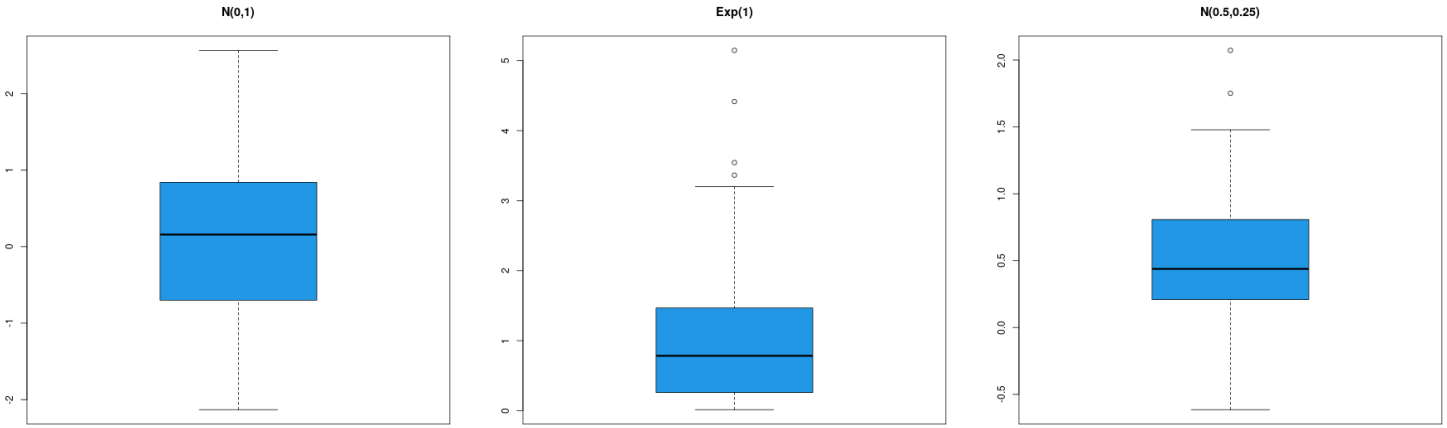

Histogramme

Les histogrammes doivent montrer une distribution en cloche.

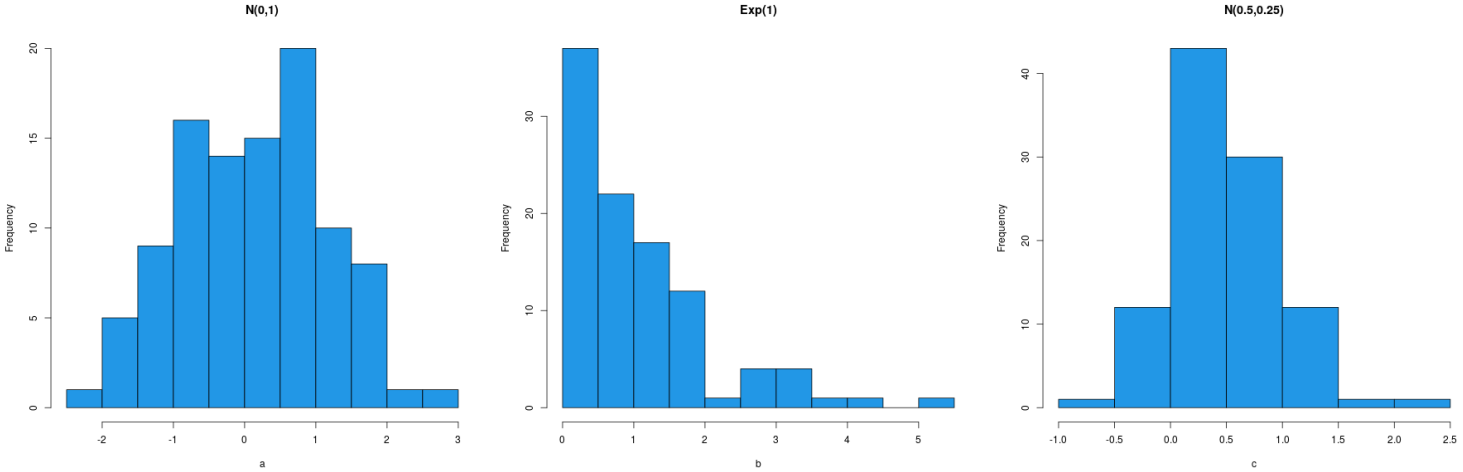

QQ-plot

Les qq-plots doivent montrer l'adéquation de deux distributions.

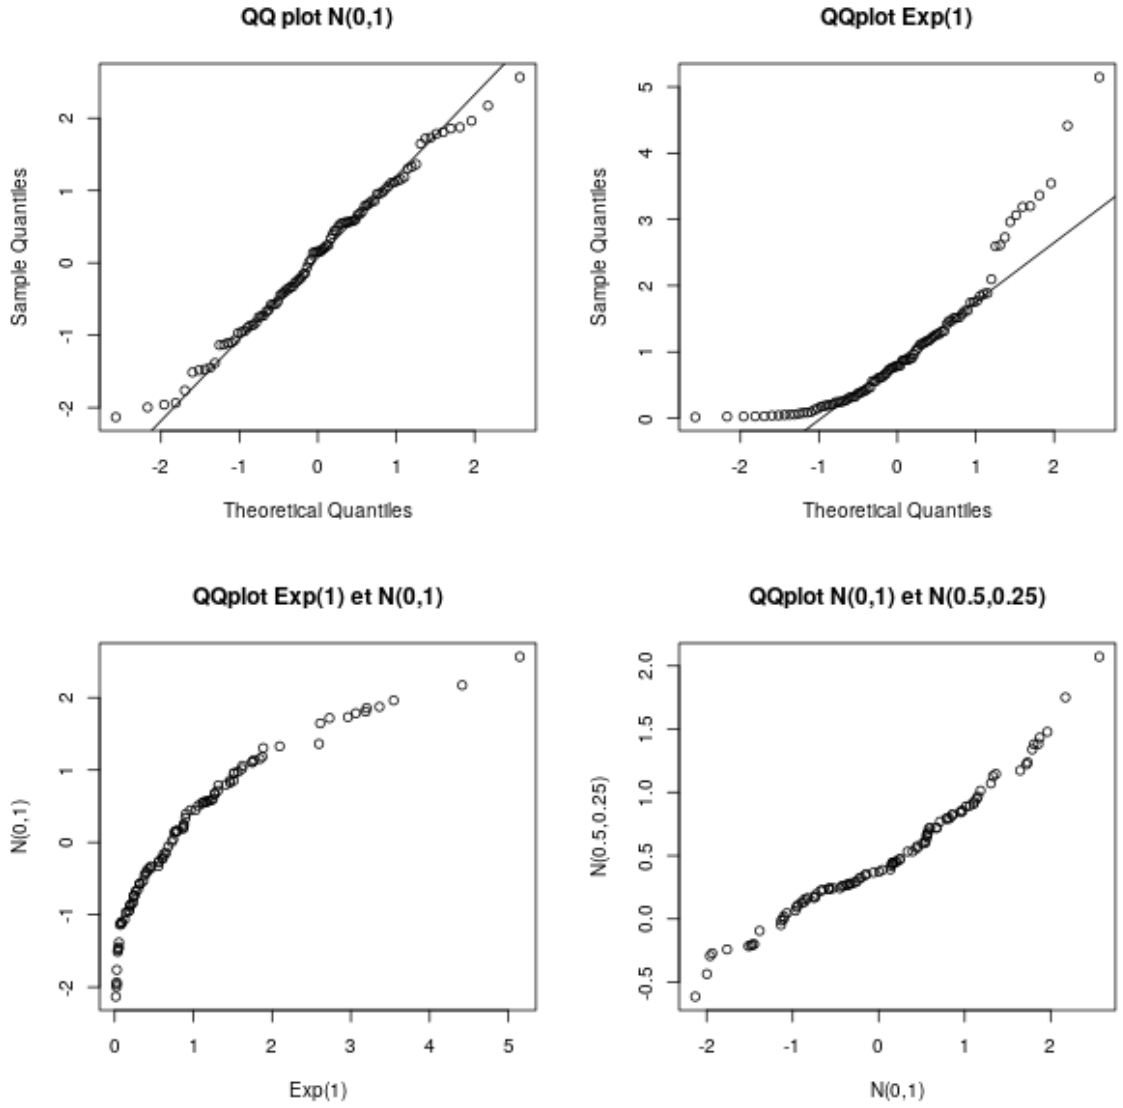

Hétéroscédasticité

En traçant en abscisse l'indice et en ordonnée la valeur du résidu standard, les points doivent rester entre deux droites d'ordonnée -2 et 2

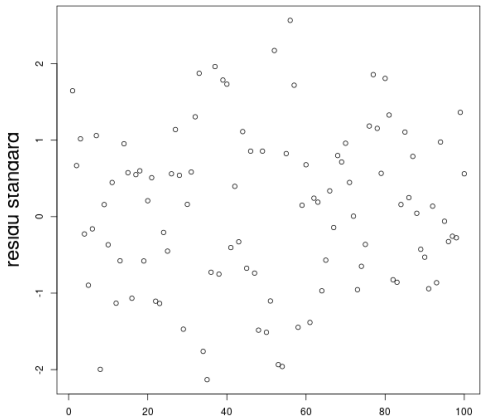

(g) homoscédasticité

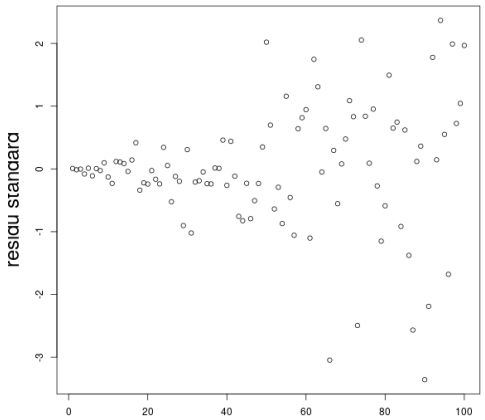

(h) hétéroscédasticité

Vérification des conditions : méthodes analytiques

Pour tester l'indépendance des résidus

- test de Durbin-Watson (pour l'autocorrelation)

Pour tester la normalité les tests suivants peuvent être effectués (par ordre de puissance croissante)

- test du χ^2
- test de Kolmogorov-Smirnov
- test de Shapiro-Wilk

Pour tester l'homoscédasticité

- test de Fisher
- test de Breush-Pagan

Rappel Les hypothèses sont rejetées si la p-valeur est inférieure au seuil de test (souvent 5%)

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Régression logistique simple

Données

- Une variable X
- Une variable binaire Y

Hypothèse $Y = \frac{1}{1+\exp(-b_0-bX)}$

Transformation

- $Y' = logit(Y) = \log(\frac{Y}{1-Y})$
- $Y' = b_0 + bX$

Test de Wald

- $H_0 : b = 0$ et $H_1 : b \neq 0$
- la statistique $W = \frac{\hat{b}}{s^2_{\hat{b}}}$ suit une loi χ^2 à 1 degré de liberté
- $s_{\hat{b}}$ est l'écart type de l'estimateur $\hat{b}$
- rejeter cette hypothèse implique qu'il y a un lien entre X et Y

Régression logistique multivarié

Données

- Des variables $X_1, \ldots, X_P$ qualitatives ou quantitatives
- Une variable binaire Y

Hypothèse $Y = \frac{1}{1+\exp(-b_0-\sum_{p=1}^{P} b_p X_p)}$

Transformation

- $Y' = logit(Y) = b_0 + \sum_{p=1}^{P} b_p X_p$

Test de Wald

- appliquer le test à chaque b_p
- rejeter cette hypothèse implique qu'il y a un lien entre X_p et Y

Régression logistique et odds ratio

Pour une variable binaire X_i, le rapport des cotes ou odds ratio est donnée par

$$OR_p = \frac{\frac{\#\{X_p=1 \cap Y=1\}}{\#\{X_p=0 \cap Y=1\}}}{\frac{\#\{X_p=1 \cap Y=0\}}{\#\{X_p=0 \cap Y=0\}}}$$

L'odds ratio est lié au coefficient b_p par

$$b_p = \log(OR_p) \Leftrightarrow OR_p = \exp(b_p)$$

Table des matières

Introduction

Théorèmes fondamentaux des statistiques

Méthode des moments

Méthode Delta

Qualité d'un estimateur

Maximum de vraisemblance

Modèle linéaire Gaussien

Modèle de régression logistique

Sélection du modèle

Critère de sélection

Objectif

- Comparaison de plusieurs modèles ayant un nombre de paramètres différents
- Choisir le modèle qui minimise la perte d'information

Un bon modèle doit minimiser l'un de ces critères :

- Critère AIC d'Akaïké : $AIC = -2log(L(\hat{\theta})) + 2k$
- Critère BIC de Schwartz : $BIC = -2log(L(\hat{\theta})) + log(n)k$

avec k le nombre de paramètres du modèle et $L(\hat{\theta})$ la vraisemblance calculée en le paramètre estimé $\hat{\theta}$.

- Pour un grand nombre d'observations, le BIC aura tendance à favoriser des modèles à moins de paramètres que le AIC

Test pour la sélection

Test du rapport de vraisemblance

- comparaison entre un modèle contraint et non contraint
- $H_0 : \theta \in \Theta_0$ contre $H_1 : \theta \notin \Theta_0$
- $\lambda = -2 \log \left(\frac{L(\hat{\theta}_0)}{L(\hat{\theta})} \right)$ avec $\hat{\theta}_0$ le MV sous H_0
- sous $H_0 : \lambda \sim \chi^2(p)$ avec p le nombre de contraintes

Test des multiplicateurs de Lagrange

- $H_0 : \theta = \theta_0$ contre $H_1 : \theta \neq \theta_0$
- sous $H_0 : S = \frac{1}{I(\theta_0)} \left(\frac{dL(x_1,\ldots,x_n;\theta_0)}{d\theta} \right)^2 \sim \chi^2(1)$

Test de Wald

- comparaison entre le MV et une valeur θ_0
- $H_0 : \theta = \theta_0$ contre $H_1 : \theta \neq \theta_0$
- sous $H_0 : W = \frac{(\hat{\theta}-\theta_0)^2}{var(\hat{\theta})} \sim \chi^2(1)$

Modélisation statistique avancée

BUT SD 3A S5
2023-2024

Partie 2 : Statistique non paramétrique

Christophe REYPE

© 2023 Christophe REYPE
Document sous licence Creative Commons Attribution – Partage dans les mêmes conditions 4.0 International (CC BY-SA 4.0)
https://creativecommons.org/licenses/by-sa/4.0/

Table des matières

Introduction

Tests non paramétriques

Estimation de la densité par l'histogramme

Estimation de la densité par la méthode du noyau

Régressogramme

Pourquoi l'estimation non paramétrique ?

Rappel : Les statistiques paramétriques reposent sur l'hypothèse que les distributions des variables aléatoires sont des fonctions définies par un nombre fini de paramètres.

Questions :

1) Que faire si nous avons de l'information sur les paramètres ?
2) Que faire si le nombre de paramètres dépend du nombre d'observation ?
3) Que faire si nous n'avons aucune information sur les distributions des variables aléatoires ?

Réponse :

- Pour la question 1), il faut faire des statistiques bayésiennes
- Pour les questions 2) et 3), il faut faire des statistiques non paramétrique

La statistique non paramétrique

Objectif : La distribution des variables aléatoires est estimée soit par sa densité soit par sa fonction de répartition

Idées : L'estimateur de la fonction devrait

- bien être une densité (ou une fonction de répartition le cas échéant)
- converger vers la vraie fonction
- être sans biais

Problème : L'estimateur ne peut pas être sans biais en tout point

Remarque : L'idée étant d'estimer une fonction, l'estimation non paramétrique est aussi appelé estimation fonctionnelle

Concernant la convergence

Contexte : Soit $\hat{f}_n(x)$ un estimateur de la densité $f(x)$

Convergence : Pour vérifier de la qualité de l'estimateur, il faut

- vérifier la convergence en tout point
- borner l'erreur d'estimation maximale $\sup_x |\hat{f}_n(x) - f(x)|$

MISE L'erreur quadratique moyenne intégrée (MISE) mesure l'écart entre l'estimateur et la densité inconnue

$$MISE = \mathbb{E}\left(\int_{\mathbb{R}} (\hat{f}_n(x) - f(x))^2 dx\right)$$

Table des matières

Introduction

Tests non paramétriques

Estimation de la densité par l'histogramme

Estimation de la densité par la méthode du noyau

Régressogramme

Test du χ^2

Contexte : Soit X une variable de loi discrète à K classes où chaque classe k est de probabilité p_k. Soit l'échantillon composé de n réalisations donnant pour chaque classe k l'effectif N_k. De plus $\mathbb{E}(N_k) = np_k$. Le test s'effectue si pour tout k, np_k est supérieur à un certain seuil (5, 3 ou 1 pour une classe en queue de distribution)

Hypothèses : $H_0 : \forall k \leq K : \ p_k = p_{K,0}$ et
$H_1 : \exists k \leq K : \ p_k \neq p_{K,0}$

Test : Sous H_0, $D^2 = \sum_{k=1}^{K} \frac{(N_i - np_k)^2}{np_k} \sim \chi^2_{K-1}$

Test de Kolmogoroff Smirnov

Contexte : L'objectif est de comparer deux fonctions de répartition. Soient l'échantillon d'intérêt composé des variables aléatoire $X_1, \ldots, X_n$ iid suivant F et un échantillon composé des variables aléatoire $Y_1, \ldots, Y_m$ iid suivant une fonction de répartition connue F_0.

Hypothèses : $H_0 : F = F_0$ et $H_1 : F \neq F_0$

Test : Sous H_0, $\sqrt{\frac{nm}{n+m}} \sup_x \{F_n(x) - F_0(x)\}$ suit une loi tabulée

Notation : $\forall x \in \mathbb{R} : F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{X_i \leq x}$

Test de Wilcoxon-Mann-Whitney

Contexte : L'objectif est de comparer deux échantillons $(x_1, \ldots, x_n)$ et $(y_1, \ldots, y_m)$. Si leur distribution est la même, lorsque les données sont ordonnées, le mélange doit être homogène. Soit U la variable aléatoire qui compte le nombre de fois où une donnée x_i est inférieure à une donnée y_j. Cette statistique est appelée statistique de Mann-Whitney.

Hypothèses :

- Si les distributions sont les mêmes : $\mathbb{E}(U) = \frac{nm}{2}$ et $Var(U) = \frac{nm(n+m+1)}{12}$
- Asymptotiquement U est gaussien. Souvent il suffit de prendre $n > 8$ et $m > 8$

Test de Wilcoxon de la somme des rangs

Contexte : La statistique d'intérêt est ici la somme des rangs d'un échantillon noté W_X.

Hypothèse : Sous H_0

- $\mathbb{E}(W_X) = \frac{n(n+m+1)}{2}$ et $Var(W_X) = \frac{nm(n+m+1)}{12}$
- $\frac{W_X - \mathbb{E}(W_X)}{\sqrt{Var(W_X)}} \sim \mathcal{N}(0,1)$

Table des matières

Introduction

Tests non paramétriques

Estimation de la densité par l'histogramme

Estimation de la densité par la méthode du noyau

Régressogramme

Estimation par histogramme

Histogramme : Pour construire l'histogramme, il faut

- définir l'amplitude des classes, souvent prendre des classes de même amplitude h
- pour chaque classe, compter le nombre de données dans chaque classes
- reporter les résultats dans une figure avec en abscisse les classes et en ordonnée la fréquence de chaque classe

Remarque : L'histogramme est l'estimateur le plus élémentaire

Convergence : Pour assurer la convergence il faut

- faire tendre h vers 0 quand n tend vers ∞
- que $nh \to \infty$

En pratique : Il suffit de prendre $h = \frac{constante}{\sqrt{n}}$

Limites de l'histogramme

Critiques :

- L'histogramme est discontinue
- Dans une classe, chaque point à la même densité

Méthode de la fenêtre mobile

Idées :

- Les classes ont la même amplitude h
- Les classes sont centrées autours des observations
- Pour chaque x la classe correspondante est $[x - h/2; x + h/2]$
- L'estimation en x de la densité est $\hat{f}_n(x) = \frac{n_x}{nh}$ avec n_x le nombre d'observation dans la classe centrée en x

Limite : L'estimateur est toujours discontinue lorsque x prends une des valeurs x_i des données

Table des matières

Introduction

Tests non paramétriques

Estimation de la densité par l'histogramme

Estimation de la densité par la méthode du noyau

Régressogramme

De l'estimateur de la fenêtre mobile à l'estimateur à noyau

L'estimateur de la fenêtre mobile peut se réécrire

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right) = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{h} K\left(\frac{x - x_i}{h}\right)$$

avec

$$\forall u \in \mathbb{R} : \; K(u) = \begin{cases} 1 \text{ si } \dfrac{-1}{2} \leq u \leq \dfrac{1}{2} \\ 0 \text{ sinon} \end{cases}$$

Remarques :

- $\hat{f}_n$ est discontinue car K est discontinue
- $\hat{f}_n$ est une moyenne arithmétique donnant à chaque observation x_i une pondération $\frac{1}{h}$ si elle est dans un intervalle centrée en x

Le noyau

Definition (Noyau)

Un fonction $K : \mathbb{R} \to \mathbb{R}$ est un noyau si $\int_{\mathbb{R}} K(u)du = 1$.

Remarque : Si K est en plus positive alors K est une densité

Proposition : $\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x-x_i}{h}\right)$ est appelée estimateur à noyau et vérifie $\int_{\mathbb{R}} \hat{f}_n(x)dx = 1$. De plus si K est positif alors $\hat{f}_n(x)$ est une densité

Remarques :

- h est appelé fenêtre
- h est un paramètre de lissage : plus il est grand et plus l'estimateur sera régulier
- Le choix de K a peu d'impact sur l'estimation de la densité contrairement au choix de la fenêtre

Les noyaux couramment utilisés

- Le noyau triangulaire $K(u) = (1 - |u|)\,\mathbb{1}_{u \in [-1;1]}$
- Le noyau parabolique d'Epanechnikov $K(u) = \left(\frac{3}{4}(1 - u^2)\right)\mathbb{1}_{u \in [-1;1]}$
- Le biweight de Tukey $K(u) = \left(\frac{15}{16}(1 - u^2)^2\right)\mathbb{1}_{u \in [-1;1]}$
- Le noyau sinusoïdale $K(u) = \frac{\pi}{4} cos\left(\frac{\pi}{2}u\right)\mathbb{1}_{u \in [-1;1]}$
- Le noyau gaussien $K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right)$

Calcul du biais de l'estimateur par noyau

Proposition Si f est dérivable en x, de dérivée bornée et si $\int_{\mathbb{R}} |uK(u)du| < \infty$ alors $\mathbb{E}(\hat{f}_n(x)) = f(x) + \mathcal{O}(h)$.

Remarque : Le biais de $\hat{f}_n(x)$ est $f(x)$ plus une fonction du même ordre de grandeur que h

Calcul de la variance de l'estimateur par noyau

Proposition Si f est bornée, de dérivée bornée et si $\int_{\mathbb{R}} K^2(u)du < \infty$ alors en posant $\|f\|_\infty = \max_x f(x)$

$$var(\hat{f}_n(x)) \leq \frac{\|f\|_\infty \int_{\mathbb{R}} K^2(u)du}{nh}.$$

Choix de la fenêtre

Le choix de h se fait généralement en suivant l'une de ces règles

- inspection visuelle
- règle gaussienne $h = \hat{\sigma}\left(\frac{4}{3n}\right)^{1/5}$
- règle de Silverman $h = \frac{0.9 \min\left\{\hat{\sigma};\left(\frac{Q_3 - Q_1}{1.34}\right)\right\}}{n^{1/5}}$
- minimum du MSE $h = \arg\min_h \{\mathbb{E}\left[\int_{\mathbb{R}} (\hat{f}_n(x) - f(x))^2 dx\right]\}$

Table des matières

Introduction

Tests non paramétriques

Estimation de la densité par l'histogramme

Estimation de la densité par la méthode du noyau

Régressogramme

Pourquoi l'estimation par régressogramme ?

Rappel : Le principe de la régression est de supposer qu'il y a un lien entre une variable d'intérêt Y et une variable explicative X. Ce lien est de la forme d'une fonction g de sorte que $Y = g(X)$.

Question : Que faire si nous n'avons aucune information sur la fonction g ?

Idée du régressogramme

- Placer les données dans le plan défini par en abscisse les valeurs de X et en ordonnée les valeurs de Y
- Découper l'axe des abscisses en classes
- Pour chaque classe, calculer la valeur moyenne des Y
- Le régressogramme est la fonction défini par la valeur moyenne des Y sur chaque classe

Régressogramme

Régressogramme :

- Les classes ont la même amplitude h
- Le découpage en classe commence en une valeur t_0 fixée par l'utilisateur
- La classe numéro k est de la forme $[t_0 + hk; t_0 + h(k+1)[= [t_k; t_{k+1}[$
- L'estimation en x de la densité est, en posant n le nombre d'observations

$$\forall x \in [t_k; t_{k+1}[: \ \hat{g}_n(x) = \frac{\sum_{i=1}^n y_i \mathbb{1}_{x_i \in [t_k; t_{k+1}[}}{\sum_{i=1}^n \mathbb{1}_{x_i \in [t_k; t_{k+1}[}}$$